




Ajuste de distribuciones

Rodrigo Maranzana

De los datos a los parámetros




Población con distribución Normal

¿Cómo conozco sus parámetros μ y σ ?

Supuestos:

- * Muestras aleatorias.
- * Conozco la distribución de los datos.


Muestra



Probabilidad


Recordemos: probabilidad de X $\rightarrow P(X) = P(X|\theta)$

Tal que conozco sus parámetros θ



*fdp: función de densidad de probabilidad.

Verosimilitud (likelihood)



Sample Likelihood

Verosimilitud (Likelihood)


De la muestra:

$$L(\theta|X_1, X_2, \dots, X_n)$$


$$= L(\theta|X_1)L(\theta|X_2) \dots L(\theta|X_n)$$

$$= \prod_i^n L(\theta|X_i)$$

Visualización de función de Likelihood




Visualización de función de Likelihood



Ejemplo: estimación de flujo vehicular

- Conozco el parámetro de servicio de agentes μ , ya que es un proceso controlable.
- En un control de tránsito, **necesito estimar el parámetro de llegada de vehículos λ** .
- La distribución de “tiempo entre llegadas” se supone exponencial.
- Puedo aplicar ajuste paramétrico de distribución.

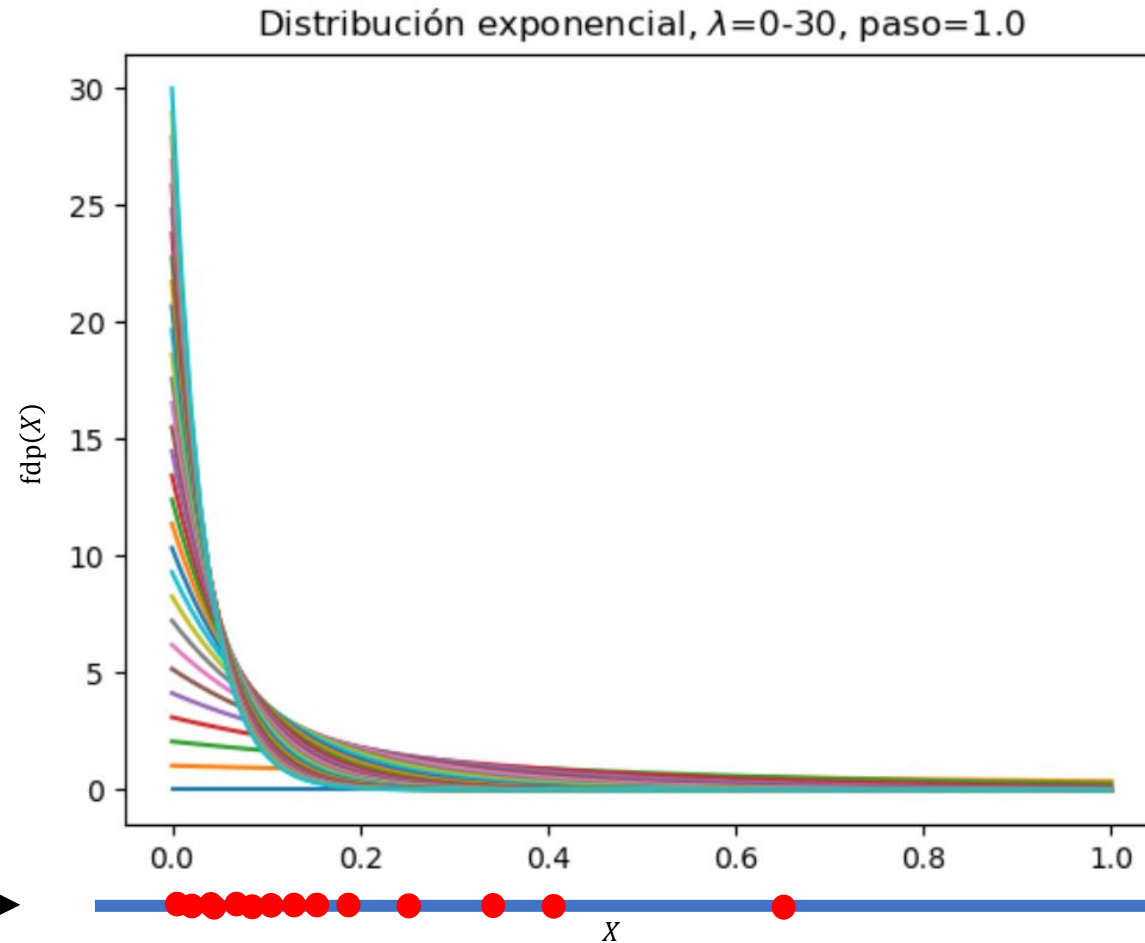


¿Cómo paso de los datos al parámetro λ ?

Distribución exponencial gráficamente

¿Cuál es el λ óptimo para esta distribución?

Muestra →



Solución analítica de Maximum Likelihood

Para este caso: **¡existe solución analítica de la Verosimilitud Máxima!**

$$L(\theta|X_i \dots X_n) = \prod_i^n L(\theta|X_i) \quad \text{Dado que: } L(\theta|X_i) = f_\theta(X_i)$$

En la exponencial:

$$f_\lambda(X) = \lambda e^{-\lambda x} \quad \downarrow$$
$$L(\lambda|X_i \dots X_n) = \prod_i^n L(\lambda|X_i) = \prod_i^n \lambda e^{-\lambda x_i}$$

Solución analítica de Maximum Likelihood

$$L(\lambda|X_i \dots X_n) = \prod_i^n \lambda e^{-\lambda x_i}$$

Queremos calcular:

$$\max L(\lambda|X_i \dots X_n)$$

¿Cómo encontramos el máximo analíticamente?

$$\frac{d L(\lambda|X_i \dots X_n)}{d\lambda} = 0$$

Solución analítica de Maximum Likelihood

$$\begin{aligned}L(\lambda|X_i \dots X_n) &= \prod_i^n \lambda e^{-\lambda x_i} \\&= \lambda e^{-\lambda x_1} \lambda e^{-\lambda x_2} \dots \lambda e^{-\lambda x_n} \\&= \lambda^n e^{-\lambda x_1 - \lambda x_2 - \dots - \lambda x_n}\end{aligned}$$

$$L(\lambda|X_i \dots X_n) = \lambda^n e^{-\lambda(x_1 + x_2 + \dots + x_n)}$$

$$\frac{dL(\lambda|X_i \dots X_n)}{d\lambda} = \frac{d[\lambda^n e^{-\lambda(x_1 + x_2 + \dots + x_n)}]}{d\lambda} = 0$$

Solución analítica de Maximum Likelihood

Sabemos que:

$$\max L(\lambda|X_i \dots X_n) = \max \log L(\lambda|X_i \dots X_n)$$

¡Las propiedades del logaritmo facilitan la optimización!

$$\log L(\lambda|X_i \dots X_n) = \log \lambda^n e^{-\lambda(x_1+x_2+\dots+x_n)}$$

$$= \log \lambda^n + \log e^{-\lambda(x_1+x_2+\dots+x_n)}$$

$$\log L(\lambda|X_i \dots X_n) = n \log \lambda - \lambda(x_1 + x_2 + \dots + x_n)$$

Solución analítica de Maximum Likelihood

$$\frac{dL(\lambda|X_1 \dots X_n)}{d\lambda} = \frac{d(n \log \lambda - \lambda(x_1 + x_2 + \dots + x_n))}{d\lambda} = 0$$

$$= \frac{n}{\lambda} - (x_1 + x_2 + \dots + x_n) = 0$$

$$\frac{1}{\lambda} = \beta = \frac{(x_1 + x_2 + \dots + x_n)}{n}$$

$$\lambda = \frac{1}{\beta}$$

En otras distribuciones

- ¡No todas son tan simples!
- No todas tienen solución analítica
- Uso de métodos numéricos de ajuste -> Distribución Beta
- Lo importante es: **conocer cómo armar la Función de densidad**

Resumen

- Puente entre **datos** -> **parámetros** de una Distribución
- Ajuste de datos a una densidad de probabilidad **conocida**
- Parámetros **desconocidos**

Ajuste en Python

Distribución Beta:

```
from scipy.stats import beta  
  
a, b, loc, scale = beta.fit(x)
```

**** Documentación: Solución numérica, óptimos locales!**