




# Ajuste de distribuciones

Rodrigo Maranzana

# De los datos a los parámetros




Población con distribución Normal

¿Cómo conozco sus parámetros  $\mu$  y  $\sigma$ ?

## Supuestos:

- \* Muestras aleatorias.
- \* Conozco la distribución de los datos.


Muestra



# Probabilidad


Recordemos: probabilidad de  $X$   $\rightarrow P(X) = P(X|\theta)$

Tal que conozco sus parámetros  $\theta$



\*fdp: función de densidad de probabilidad.

# Verosimilitud (likelihood)



# Sample Likelihood

**Verosimilitud** (Likelihood)


De la muestra:

$$L(\theta|X_1, X_2, \dots, X_n)$$


$$= L(\theta|X_1)L(\theta|X_2) \dots L(\theta|X_n)$$

$$= \prod_i^n L(\theta|X_i)$$

# Visualización de función de Likelihood




# Visualización de función de Likelihood





# Ejemplo: estimación de flujo vehicular

- Conozco el parámetro de servicio de agentes  $\mu$ , ya que es un proceso controlable.
- En un control de tránsito, **necesito estimar el parámetro de llegada de vehículos  $\lambda$** .
- La distribución de “tiempo entre llegadas” se supone exponencial.
- Puedo aplicar ajuste paramétrico de distribución.



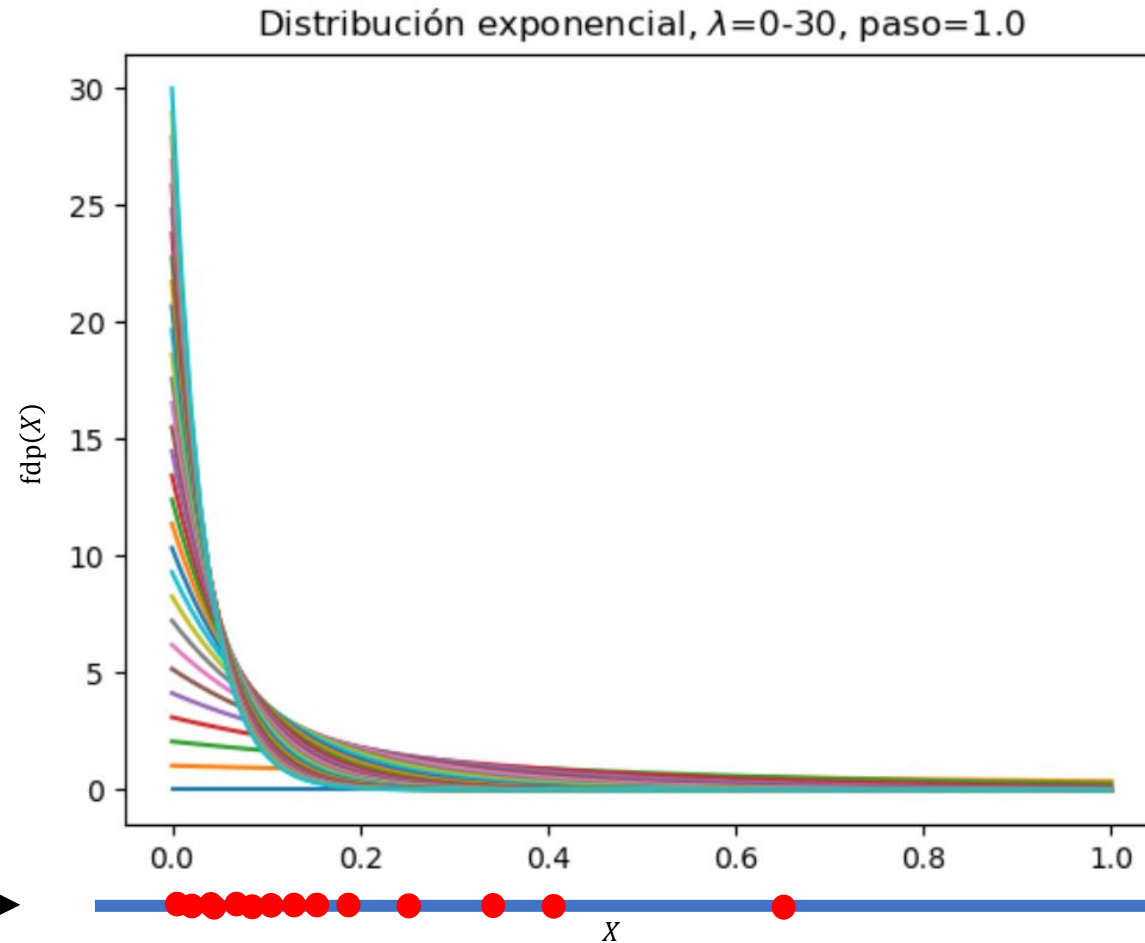
¿Cómo paso de los datos al parámetro  $\lambda$ ?



# Distribución exponencial gráficamente

¿Cuál es el  $\lambda$  óptimo para esta distribución?

Muestra →



# Solución analítica de Maximum Likelihood

Para este caso: **¡existe solución analítica de la Verosimilitud Máxima!**

$$L(\theta|X_i \dots X_n) = \prod_i^n L(\theta|X_i) \quad \text{Dado que: } L(\theta|X_i) = f_\theta(X_i)$$

En la exponencial:

$$f_\lambda(X) = \lambda e^{-\lambda x} \quad \downarrow$$
$$L(\lambda|X_i \dots X_n) = \prod_i^n L(\lambda|X_i) = \prod_i^n \lambda e^{-\lambda x_i}$$

# Solución analítica de Maximum Likelihood

$$L(\lambda|X_i \dots X_n) = \prod_i^n \lambda e^{-\lambda x_i}$$

Queremos calcular:

$$\max L(\lambda|X_i \dots X_n)$$

¿Cómo encontramos el máximo analíticamente?

$$\frac{d L(\lambda|X_i \dots X_n)}{d\lambda} = 0$$

# Solución analítica de Maximum Likelihood

$$\begin{aligned} L(\lambda|X_i \dots X_n) &= \prod_i^n \lambda e^{-\lambda x_i} \\ &= \lambda e^{-\lambda x_1} \lambda e^{-\lambda x_2} \dots \lambda e^{-\lambda x_n} \\ &= \lambda^n e^{-\lambda x_1 - \lambda x_2 - \dots - \lambda x_n} \end{aligned}$$

$$L(\lambda|X_i \dots X_n) = \lambda^n e^{-\lambda(x_1 + x_2 + \dots + x_n)}$$

$$\frac{dL(\lambda|X_i \dots X_n)}{d\lambda} = \frac{d[\lambda^n e^{-\lambda(x_1 + x_2 + \dots + x_n)}]}{d\lambda} = 0$$

# Solución analítica de Maximum Likelihood

Sabemos que:

$$\max L(\lambda|X_i \dots X_n) = \max \log L(\lambda|X_i \dots X_n)$$

¡Las propiedades del logaritmo facilitan la optimización!

$$\log L(\lambda|X_i \dots X_n) = \log \lambda^n e^{-\lambda(x_1+x_2+\dots+x_n)}$$

$$= \log \lambda^n + \log e^{-\lambda(x_1+x_2+\dots+x_n)}$$

$$\log L(\lambda|X_i \dots X_n) = n \log \lambda - \lambda(x_1 + x_2 + \dots + x_n)$$

# Solución analítica de Maximum Likelihood

$$\frac{dL(\lambda|X_1 \dots X_n)}{d\lambda} = \frac{d(n \log \lambda - \lambda(x_1 + x_2 + \dots + x_n))}{d\lambda} = 0$$

$$= \frac{n}{\lambda} - (x_1 + x_2 + \dots + x_n) = 0$$

$$\lambda = \frac{(x_1 + x_2 + \dots + x_n)}{n}$$

# En otras distribuciones

- ¡No todas son tan simples!
- No todas tienen solución analítica
- Uso de métodos numéricos de ajuste -> Distribución Beta
- Lo importante es: **conocer cómo armar la Función de densidad**



# Resumen

- Puente entre **datos** -> **parámetros** de una Distribución
- Ajuste de datos a una densidad de probabilidad **conocida**
- Parámetros **desconocidos**

# Ajuste en Python

Distribución Beta:

```
from scipy.stats import beta  
  
a, b, loc, scale = beta.fit(x)
```

**\*\* Documentación: Solución numérica, óptimos locales!**